

Aproximación a la identificación de la minería ilegal en videos de cámaras FLIR a partir de la detección y la diferenciación de carreteras no pavimentadas y cuerpos de agua

María Alejandra Ariza Rangel*, Camilo Andrés Daza Ramírez†,
María Paola Reyes Gómez*, Juan Diego Yepes Parra‡

*Maestría en Biología Computacional,

†Pregrado en Ingeniería de Sistemas y Computación,

‡Maestría en Ingeniería de Sistemas y Computación,

Facultad de Ingeniería, Universidad de los Andes, Bogotá, Colombia

Resumen—La Fuerza Aeroespacial Colombiana (FAC), en alianza con la Universidad de los Andes, busca modernizar sus procesos mediante soluciones innovadoras para la protección ambiental. Su principal objetivo es preservar la Amazonia Colombiana mediante el análisis de videos capturados con sensores aerotransportados para detectar minería ilegal.

Este análisis, tradicionalmente manual, ahora se enfocará en la detección automatizada de carreteras no pavimentadas y cuerpos de agua. Esta automatización optimiza la identificación de áreas afectadas, mejorando la precisión y eficiencia del proceso.

Se prevén tres beneficios clave: reducción del tiempo y errores en la identificación mediante inteligencia artificial, mejora en la segmentación de imágenes y fortalecimiento de la toma de decisiones en operaciones militares.

Además, esta tecnología tiene aplicaciones más amplias, como el apoyo a imágenes satelitales para la planeación militar, el monitoreo de la deforestación y la gestión de recursos hídricos. También puede contribuir a la formulación de políticas ambientales, al fortalecimiento de la seguridad en la región y al desarrollo de nuevas investigaciones.

Index Terms—Palabras clave; separadas; por punto y coma.

I. INTRODUCCIÓN

I-A. Objetivo General

Diseñar y desarrollar un modelo basado en aprendizaje profundo (deep learning) para el procesamiento de imágenes extraídas de videos, para mejorar su calidad, eliminar ruido y automatizar la detección de cuerpos de agua y carreteras no pavimentadas, facilitando así la identificación automática de estos elementos y contribuyendo al reconocimiento de campamentos de minería ilegal.

I-B. Objetivos Específicos

1. Implementar técnicas de preprocesamiento de imágenes que permitan mejorar la calidad de los fotogramas extraídos de los videos, eliminando ruido y mejorando el contraste, con una reducción mínima del 20 % en la distorsión de la imagen.

2. Diseñar y entrenar un conjunto de datos etiquetado para la identificación de carreteras no pavimentadas y cuerpos de agua.
3. Desarrollar un modelo de aprendizaje profundo basado en redes neuronales convolucionales para la detección y clasificación de carreteras no pavimentadas y cuerpos de agua en videos capturados por cámaras FLIR.
4. Evaluar el desempeño del modelo mediante métricas de clasificación como precisión, recall y F1-score, con un umbral mínimo de 80 % en cada una, para validar su aplicabilidad en escenarios reales de detección de minería ilegal.

II. ESTADO DEL ARTE

Recientemente, el aprendizaje automático y la visión por computadora han mejorado significativamente el monitoreo ambiental mediante imágenes satelitales, especialmente en áreas como la detección de pistas clandestinas en la Amazonía. En este contexto, Pardini et al. [1] desarrollaron un modelo basado en redes neuronales para reducir los falsos positivos en un 26.6 %, optimizando el procesamiento de 43 a 32 horas mediante paralelización.

En la gestión hídrica, Albuquerque Teixeira et al. [2] aplicaron redes neuronales para segmentar embalses en Brasil, alcanzando una precisión del 95 % en la Intersección sobre Unión (IoU), mejorando así la monitorización de recursos hídricos en zonas semiáridas.

Por otro lado, Ferreira et al. [3] implementaron una fusión de datos de teledetección para detectar cultivos ilícitos, alcanzando una precisión del 92.16 % y reduciendo los falsos positivos al 5.87 %. Este enfoque es particularmente útil para identificar cultivos ilegales, como la *Cannabis Sativa*, en Brasil.

Pinto Hidalgo et al. [4] crearon un modelo con redes neuronales y datos geoespaciales para detectar infraestructuras de producción de coca en la frontera Venezuela-Colombia. Su

metodología mejoró la vigilancia en zonas de difícil acceso, usando imágenes satelitales y bases de datos geospaciales.

En cuanto a la detección de carreteras ilegales, Sloan et al. [5] utilizaron redes U-Net y ResNet-34 para identificar carreteras en Asia Pacífico con una precisión entre el 72 % y el 81 %. Su metodología podría aplicarse en ecosistemas tropicales para monitorear el impacto ambiental de infraestructuras no autorizadas.

A pesar de estos avances, aún existen desafíos en la optimización de modelos para diferentes condiciones geográficas y climáticas, y en la reducción de costos computacionales sin afectar la precisión. Estos estudios ofrecen valiosas herramientas para mejorar la vigilancia ambiental y la gestión sostenible de los recursos naturales.

III. MATERIALES

Se cuenta con aproximadamente 25 minutos de video etiquetados, que fueron divididos en alrededor de 4000 fotogramas en formato png, los cuales le pertenecen a la FAC, las cuales son obtenidas de cámaras FLIR (Forward-Looking Infrared), los cuales son sensores térmicos avanzados que permiten la detección de objetos y actividades a partir de radiación infrarroja emitida por los cuerpos. Los fotogramas tienen varias capturas de diferentes tipos de territorio, entre montañas, cuerpos de agua, carretera, vehículos, entre otros; cuenta también con coordenadas de imágenes para la identificación de objetos dentro de la misma y con problemas como exceso de ruido, distorsión, sombra y baja resolución de los fotogramas. Se adjunta el notebook con un primer procesamiento de las imágenes para mejorar su calidad y disminuir el ruido en las mismas.

IV. MÉTODOS

El proyecto se enfoca en mejorar imágenes mediante preprocesamiento, reducción de ruido y optimización visual. Se inició con 28 imágenes exploratorias para pruebas antes de aplicarlo a un conjunto de datos mayor. Primero, se verifican el tipo y dimensiones de cada imagen. Luego, se convierten a escala de grises para simplificar el análisis y reducir la complejidad computacional, ajustándolas al formato unit8 sin pérdida de información. Después, se genera el histograma de intensidad para analizar contraste y distribución de píxeles. Luego, se aplica la ecualización del histograma para mejorar la visibilidad. Para reducir ruido y resaltar detalles, se usan filtros como el bilateral, que suaviza sin perder bordes, y el laplaciano, que enfatiza contornos. Un proceso automatizado aplica estos pasos a todas las imágenes. Los resultados se evalúan comparando imágenes originales y procesadas. Se prueban combinaciones adicionales de filtros, como el de mediana y el gaussiano, para optimizar la nitidez. Esta fase exploratoria garantiza la efectividad del método antes de su aplicación en un conjunto de datos mayor.

Para llevar a cabo este proceso, se utilizan diversas herramientas y bibliotecas especializadas en procesamiento de imágenes y análisis de datos, las cuales están alineadas con los objetivos del proyecto optimizando tiempo de procesamiento




Figura 1. Flujo de trabajo para el procesamiento de imágenes.

por medio de la automatización. Algunas de las herramientas clave incluyen:

- **Python:** El lenguaje de programación utilizado para implementar la solución.
- **OpenCV:** Biblioteca para el procesamiento de imágenes.
- **Matplotlib:** Utilizada para visualizar y comparar las imágenes procesadas.
- **NumPy:** Biblioteca esencial para la manipulación de matrices.

Adicionalmente, el flujo de trabajo (Figura 1) asegura que las imágenes sean procesadas de manera eficiente y efectiva, permitiendo mejorar su calidad visual y, al mismo tiempo, optimizar el tiempo de procesamiento a través de la automatización de tareas repetitivas. Las imágenes exploratorias sirven como un paso intermedio para validar las técnicas antes de aplicar el proceso al conjunto de datos completo.

V. RESULTADOS

VI. DISCUSIÓN Y CONCLUSIÓN

REFERENCIAS

- [1] G. R. Pardini, P. M. Tasinaffo, E. H. Shiguemori, T. N. Kuck, M. R. Maximo, and W. R. Gytoku, "Improved algorithm to detect clandestine airstrips in amazon rainforest," *Algorithms*, vol. 18, no. 2, p. 102, 2025.
- [2] A. M. de Albuquerque Teixeira, L. V. Batista, R. M. da Silva, L. M. T. Freitas, and C. A. G. Santos, "Dynamic monitoring of surface area and water volume of reservoirs using satellite imagery, computer vision and deep learning," *Remote Sens. Appl.: Soc. Environ.*, vol. 35, p. 101205, 2024.
- [3] A. Ferreira, S. C. Felipussi, R. Pires, S. Avila, G. Santos, J. Lambert, and A. Rocha, "Eyes in the skies: A data-driven fusion approach to identifying drug crops from remote sensing images," *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.*, vol. 12, no. 12, pp. 4773–4786, 2019.
- [4] J. J. P. Hidalgo and J. A. S. Centeno, "Geospatial intelligence and artificial intelligence for detecting potential coca paste production infrastructure in the border region of venezuela and colombia," *J. Appl. Secur. Res.*, vol. 18, no. 4, pp. 1000–1050, 2023.
- [5] S. Sloan, R. R. Talkhani, T. Huang, J. Engert, and W. F. Laurance, "Mapping remote roads using artificial intelligence and satellite imagery," *Remote Sens.*, vol. 16, no. 5, p. 839, 2024.